

A股短中线多头预测的 IC 提升与评估体系可执行研究计划

根因诊断

下面按“最可能贡献到你当前 IC 偏低/不稳 的影响力 + 可验证性”排序。每条都给出：**证据**（对应你给出的实验现象）、**可能机制**、**如何验证**（可落地实验/检查）。其中第一个和第二个我认为是“先不修/不量化就会浪费后续两周算力”的硬前提。

评价口径与交易目标错位

证据（来自你提供的现象）

你在静态训练阶段出现了“valid IC 明显为正，但 test 全时段平均为负”，并且月度 IC 明显非平稳（同一 head 在不同月份正负切换，且存在极端好/极端差月）。你还观察到对静态模型做“整体反号”后，test IC 从 -0.0598 直接变为 +0.0598；月度 walk-forward 反号校准也能把 test avg_ic 从 -0.0598 拉到 +0.0446（dim11）。这些都强烈指向：**你当前用于早停/选模的“IC统计口径”对 regime shift 极其敏感**，同时也可能和“真正想要的横截面选股能力”不一致。

可能机制

- 1) **全样本 pooled IC**（把所有日期×股票样本堆在一起算相关）会把“时间维度上的市场漂移/基准收益漂移”混进来，从而让 IC 的符号/大小被某些时段主导；而你真正关心的是“每个交易日的横截面排序/相对收益”。此时更合理的是：按日计算横截面 IC，再对日 IC 做时间平均，并配套显著性检验（否则会被少数月份掩盖）。
- 2) 对相关系数序列（每日 IC）做显著性，不能用简单 i.i.d. 假设；金融时间序列通常存在自相关/波动聚类，应使用 HAC（例如 Newey-West）或 block bootstrap 来给 t-stat/置信区间，否则会高估有效性。¹
- 3) 你看到“按月校准能显著改善静态模型”，本质也说明：**先按“月份/ regime”切片，再评价和决策**，比单一全样本均值更贴近真实。结构性变化（break）需要被识别/隔离，不该被平均淹没。²

如何验证（最先做）

- 在不重训任何模型的前提下，把你已有 OOS 预测（rolling、static 的预测文件）统一重算三套 IC：

- 1) **Daily-CS IC**：每天对 70 只股票的预测 vs 实际做 Pearson/Spearman（RankIC），得到日序列；再计算均值/方差/ICIR、月度聚合分布。
- 2) **Monthly-CS IC**：先日 IC → 月平均，得到每月 1 个点，观察分布、胜率、最差月等。
- 3) **Pooled IC**：你现在的口径，作为对照。

- 对 Daily-CS IC 序列做 **HAC t-stat (Newey-West)** 或 **stationary bootstrap** 给出均值显著性区间，避免“看起来均值不错但其实不显著”。¹

- 如果三者差异巨大（非常可能），说明你“IC 偏低/不稳”的一部分其实是**统计口径造成的观感偏差**，后续所有选模/上线门禁必须以 Daily-CS 为主口径（见后文评价体系）。

特征—标签对齐存在“双重滞后”风险

证据（来自你仓库实现方式+你观察到 seq_len/头数的敏感性）

你仓库里：特征工程层大量特征本身就做了 `shift(1)`（例如 return 类/技术指标类都把 close 平移一日），同时序列构造 `SequenceDatasetBuilder` 又明确规定“label 时间点 t 的输入只使用到 t-1 的特征窗口”（即序列最后一个时间步对应 t-1）。这两层叠加会带来**至少 1 个交易日的额外信息滞后**：序列末端是 t-1 的特征，但该

特征又只使用到 t-2 的行情信息。

这类“过度防泄漏”的结果往往是：模型预测的有效信息被强行变旧，尤其对 3d/5d 这种短周期目标，IC 会明显受损，并且在 regime 变化时更容易发生符号翻转（因为滞后信号更像“上一阶段的因子”）。

可能机制

- 对短中线（3/5/10 日）而言，**最新 1-2 天的价格/量信息往往贡献最大**；你把它变成 t-2 的信息，会直接降低可预测性上限。
- 这也解释了你看到的：
- seq_len 并非越长越好（20 > 40；60 的 rankIC 变高但口径不完全一致），长序列可能在“信息滞后 + 非平稳”条件下反而引入更多陈旧噪声。
- 3d 头虽然噪声大，但作为辅助任务能提供稳定的梯度/共享表示（你删掉 3d 头后，整体 5d/10d 表现并未提升，反而 rankIC 下降），这符合多任务学习作为正则化的经典结论。³

如何验证（2 个最小实验就能定性）

- “不改模型，只改对齐”的 A/B：
- A（现状）：保留 feature shift(1) + builder 使用到 t-1。
- B（修正一层滞后）：二选一即可（建议先选改动最小的那条）：
- 1) **保持特征 shift(1) 不动，但把序列窗口改为包含 label 当日 t 的特征行**（因为特征行 t 本身只用到 t-1 信息，仍无未来泄漏）。
- 2) 或者：**去掉特征内部 shift(1)，仍保持 builder 使用到 t-1**（让 t-1 特征真正包含到 t-1 的信息）。
- 用 rolling18m 的同一套评估月（你当前 10 个月 OOS）重跑基线，看 **IC_5d/10d 与 RankIC_5d/10d 是否系统性抬升**；若抬升幅度在 +0.01~+0.03 量级，基本可以确定“信息滞后”是主因之一。

市场非平稳与 regime sign flip 是真实存在的，而不是“调参能解决”

证据（来自你给出的实验）

- 静态训练：valid IC ≈ 0.11 ，但 test avg_ic 为负（dim11/dim16 都发生）。
- 简单“整体反号”或“月度反号校准”能把 dim11 test avg_ic 从 -0.0598 拉到 +0.0446。
- 你展示的月度 IC 序列（2025-04 到 2026-01）在同一 head 上多次换符号，有明显结构变化。
- 引入市场状态特征（dim19）+ 滚动月度重训（18m 训练窗）后，raw OOS avg_ic 转正（0.0471），avg_rank_ic 也明显转正（0.0879）。

可能机制

- 你的 11/16 维特征本质偏“动量/趋势 + 技术指标”。而趋势因子在不同市场状态下会出现“趋势有效 $\leftrightarrow$ 反转有效”的切换，这是典型 regime 行为。
- 静态模型把训练期学到的方向固化，进入新 regime 后就表现为“信号仍有效但方向相反”。
- 市场状态特征（market_mom/vol/amount_z）能部分刻画“趋势 vs 反转”的环境，从而缓解符号翻转；滚动重训进一步让模型跟上漂移。

如何验证

- 在 Daily-CS IC 序列上跑结构变点检测（例如 Bai-Perron 多重结构断点，或至少做滚动均值/方差检验），定位“什么时候开始碎掉/翻向”。²
- 把 market_state 扩展为“更直接刻画横截面环境”的变量（见后文实验组），看是否能减少“极端坏月”的频率，而不仅仅提高均值。

校准（sign flip）在 rolling 体系里变成“二次决策噪声源”

证据

- 静态模型上：walk-forward 反号校准有显著提升（dim11）；
- rolling18m + dim19 上：校准反而把 avg_ic 从 +0.0471 拉到接近 0 或更差（你已经观察到“误翻问题”）。

可能机制

- rolling 本身已经在“每月重训”中吸收了新 regime；此时再加一个离散的 flip 决策，相当于在预测上做一个高杠杆的二次操作。
- 你的信号本来就不算很强（IC 0.03~0.07 量级），在这种信噪比下，基于短窗口历史 IC 的符号判别会非常不稳定：“翻对一次赚很多，翻错一次伤很多”。
- 换句话说：在 rolling 框架下，校准不应该是默认开启，而应该是“极端情况下的熔断/保护”，并且必须有强置信触发。

如何验证

- 用 Daily-CS IC 的 t-stat（HAC 或 bootstrap）作为触发条件：只有当“过去 K 天/ K 月 IC 显著为负（例如 $t < -2$ ）”且“在多个 horizon 上一致”时才允许 flip；否则不翻。¹
- 做“延迟确认”：信号连续 2 个评估点都满足条件才 flip（减少误翻）。

多头/多任务结构对你来说是“收益”而不是“负担”

证据

你把 3d 头真正移除后（只做 5d/10d 两头），并没有优于三头；并且在对照三头 seq20 只看 5d/10d 指标时，三头的 avg_rank_ic_5_10 反而更高（0.1100 > 0.0564）。

可能机制

- 多任务学习常见作用是“共享表示 + 辅助任务提供额外监督”，对小样本或 noisy label 场景能提高泛化稳定性。³
- 3d 虽然噪声，但它提供了“更近端、更高频的监督”，可能帮助网络学到更稳的短期价格结构，从而让 5d/10d 可迁移。

如何验证

- 不删头，而是把 3d 作为“辅助任务低权重”保留：例如 (w3,w5,w10)=(0.2,1,1) 或更低；交易与评估只看 5d/10d。观察 rankIC 是否抬升、坏月是否减少。

16 维扩展无收益，提示“扩维不是瓶颈，特征质量/尺度/冗余才是”

证据

你从 11→16 维后 valid 变差（0.0984 < 0.1103），test 几乎不变；对 16 维做常规调参也没扭转 test 负 IC。

可能机制

- 新增的 return_60d、relative_volume、macd_line/signal 等可能与已有特征强相关；在非平稳条件下，冗余特征更容易让模型“学到某个 regime 特有的组合”，从而 OOS 退化。
- 如果特征未做稳健缩放/截尾（很多量价类分布厚尾），网络在不同窗口训练出的表征会漂移更严重。

如何验证

- 对每个训练窗口做：winsorize（按分位截尾）+ robust scaling（rolling median/MAD 或按训练窗口 z-score），只在训练窗口拟合参数、在 valid/test 复用（避免泄漏）。
- 做一个“特征贡献”检查：计算每个特征对预测的敏感度/importance（简单做 permutation importance 或 SHAP 的近似），观察新增维是否真正贡献。

市场状态特征是有效方向，但你现在的 3 维可能只覆盖了“市场方向/波动/量能”三件事

证据

dim19 在静态训练相对 dim16: best_valid_ic +0.028, test_avg_ic 明显改善（-0.0647→-0.0328），rankIC 也显著抬升（-0.0563→接近 0）。进一步滚动重训后，IC/RankIC 都转正。

可能机制

- 你的股票池是 70 只行业股，横截面“相对强弱”强烈受到“市场广度、分化度、拥挤度、行业轮动速度”等影响；仅用 mom/vol/amount_z 可能还不够表达“市场内部结构”。
- 这会导致：均值能提升，但尾部月份仍会很差（因为结构没刻画够，极端环境下方向仍可能错）。

如何验证

- 增加 3~6 个“横截面结构”特征（都 shift(1)）：
- breadth：涨多跌少比例（例如 ret1d>0 的占比）
- dispersion：横截面收益标准差（分化度）
- skew/kurt：横截面偏度/峰度（肥尾/极端行情）
- corr：成分股之间平均相关（拥挤/同涨同跌）
- 看月度最差分位（例如第 10% 分位）是否改善，而不仅是均值。

“池子小 + 行业集中”天生抬高方差、压低可实现 IC 稳定性

证据

你现在的 pool 只有 70 只，且行业集中（7 个板块各 10 只）。你月度 IC 可以出现 +0.22 的极好月，也能连续几个月为负，说明统计波动很大。

可能机制

- 横截面相关系数在样本数较小时方差更大；日横截面只有 70 个点，日 IC 噪声本就高。
- 从主动管理“技能×广度”的视角看，IC 是“单次决策的技能”，要让整体稳定，还需要足够的有效广度（独立 bet 数）。⁴

如何验证

- 两条可选：
- 1) 扩大股票池（哪怕先扩到 300 只，且保持行业中性），观察月度分布是否收敛；
- 2) 不扩大池子，但把目标改成“行业内排序/行业中性后的相对收益”，减少行业共同因子对月度 IC 的扰动。

标签缺失处理可能带来“未来窗口筛样”的选择偏差

证据 / 线索

你的标签计算会把“未来 N 天窗口内出现停牌/缺价”的样本置为 NaN（以便训练时 mask）。这能避免计算错误收益，但也意味着：你在训练/评估时实际上剔除了未来会出问题的样本。

可能机制

- 如果你在研究阶段用“未来窗口是否停牌”来决定是否计入样本，统计上会产生一种“信息更干净”的选择偏差；上线时你无法预知未来停牌。
- 这会导致：回测 IC 高估、坏场景低估，尤其对短周期更明显。

如何验证

- 对比两套标签策略：
- Strategy A：现状（未来窗口有问题就 NaN）。
- Strategy B：只用“当日可交易条件”（如当日 volume>0、当日未停牌）做过滤，但不使用未来窗口筛样；未来停牌导致的收益用“最近可得价格”或“持仓冻结”规则处理（更贴近交易）。
- 看月度最差月、最大回撤类指标是否明显变化（通常会变差，但更真实）。

评价体系设计

你问的“按月 vs 全时段”不是二选一：**研发阶段与上线门禁必须分层**。核心原则是：

- **全时段（或全 OOS）均值**回答的是：这套模型的“期望 IC 是否>0、是否显著”。
- **按月（或按 regime）分布**回答的是：这套模型的“尾部风险、稳定性、是否容易被少数月份掩盖”。
- 决策上：**稳定性指标应当有否决权**，避免“均值不错但某几个月毁灭性回撤”的模型上线。

为了把体系落地，我建议将指标拆成四层，并给出一套可直接当门禁的阈值示例。

主指标

- 1) **Daily-CS IC (Pearson) 与 Daily-CS RankIC (Spearman)**：每日对 70 只股票做横截面相关，得到日序列。RankIC 本质对应 Spearman 秩相关，用于衡量排序能力。⁵
- 2) **IC_5_10 主 KPI**：只看 5d/10d 两个 head 的日 IC 均值（或按你交易侧主 horizon 加权）。
- 3) **Quantile Spread (可选但强建议)**：每天按预测排序分成 5/10 组，看 top 组未来收益均值 - bottom 组未来收益均值（或 top-bottom long-short 的日收益）。这比纯 IC 更直接与可交易性挂钩。

稳定性指标

- 1) **月度 IC 分布**：
- monthly_mean(IC_5_10) 的均值、**中位数**、10% 分位、90% 分位、最差月、最好月。
- 2) **月度胜率**：月度 IC > 0 的月份占比（或 top-bottom spread>0 的月份占比）。
- 3) **连续负月规则**：最长连续负月数、是否出现连续 ≥ 3 个月为负。
- 4) **结构变化监测**：对日 IC 序列做断点/变点检测，定位 regime 切换。²

风险指标

如果你会落到策略层（哪怕只是简单 top-k 等权），建议至少监控：

- 1) **long-short 的 Max Drawdown / Calmar**（或 top-k 超额的回撤）。
- 2) **换手率/持仓变动**：短中线模型如果通过提升 IC 获得收益，但换手爆炸，落地会失败。
- 3) **行业集中度**：你池子本身分行业，但模型可能在某些月份集中压一两个行业；这会加剧回撤与月度漂移。

上线门禁指标

两条硬性建议：

- 任何“上线门禁”必须基于 **OOS (rolling walk-forward)** 的指标；
- 门禁必须同时约束“均值”和“尾部”，否则必然被少数月份掩盖。

月度判别规则（用于稳定性否决）

以 12 个月 OOS 为理想（你当前只有 10 个月时可按 10 个月先行，但门槛要更保守）：

- **月度胜率**： $\text{win_rate_month}(\text{IC}_{5_10} > 0) \geq 60\%$ （12 个月至少 8 个正月；10 个月至少 6 个正月）。
- **最差月容忍度**： $\text{min_month}(\text{IC}_{5_10}) \geq -0.05$ （你可用历史分布再调，但必须有硬下限）。
- **连续负月**：不允许出现 ≥ 3 个月连续负 IC；一旦出现，模型仅允许“降权/熔断”而不是满仓运行。

全时段判别规则（用于显著性与期望收益）

- **均值：** $\text{mean_daily(IC_5_10)} \geq 0.05$ （你当前三头 rolling 的 5/10 平均约 0.0672，可以把 0.05 设为最低）。
- **显著性：** $\text{tstat_NW}(\text{mean_daily(IC_5_10)}) \geq 2.0$ （用 HAC 的 Newey–West 估计，避免自相关造成虚高显著性）。⁶
- **RankIC 门槛：** $\text{mean_daily(RankIC_5_10)} \geq 0.08$ 且 $\text{tstat_NW} \geq 2.0$ 。

冲突时的决策优先级

- 若 **全时段均值达标，但月度尾部不达标**：不允许上线；只能作为研究模型或作为 ensemble 的一个弱成员。
- 若 **月度稳定但均值不显著**：可以进入“观察/读数”模式（小仓位、严格止损），但不应作为主力模型。
- 若 **两者都达标**：才进入上线候选。

背后的直觉与主动管理框架一致：IC 衡量单次决策技能，稳定可实现的收益还依赖于长期一致性与足够的有效广度；不稳定的 IC 会直接推高回撤与“策略看起来好但实盘失败”的概率。

⁷

两周实验路线图

先给出“你可以直接照着跑”的 12 组最小 ablation（包含基线）。这些实验按顺序有依赖：前 3 组是“把评价与对齐修正到位”，否则后面你可能在错误口径上优化。

为了避免“不同 seq_len 导致 OOS 月份口径不一致”的问题，所有实验统一要求：

- 固定 OOS 评估月份集合（建议就用你已有的 10 个月 OOS：2025-04 ~ 2026-01），若某配置因序列长度导致少月，则其它配置也裁剪到同口径月份再对比。
- 主 KPI 统一为： IC_5_10 （日横截面均值）、 RankIC_5_10 （日横截面均值）、月度胜率/最差月。

12 组最小实验矩阵

G0 基线复现（锁定对照）

- 改动项：无（你当前最优基线：dim19 + rolling18m + valid2m + seq20 + 三头 L1 等权 + raw 预测不校准）。
- 预期方向：复现你给出的 raw OOS：avg_ic $\approx$ 0.0471、avg_rank_ic $\approx$ 0.0879；并输出 5d/10d 的 IC_5_10、RankIC_5_10（你已有三头 seq20 对照里 IC_5_10 $\approx$ 0.0672，RankIC_5_10 $\approx$ 0.1100）。
- 资源成本： $\approx 1 \times$ （10 个月重训） $\approx 30\text{--}90$ 分钟 GPU（视每月训练耗时）。
- 成败标准：复现误差在 ± 0.005 以内，否则先排查数据/随机种子/评估口径。

G1 评估口径升级（不重训，只重算指标）

- 改动项：把 IC/RankIC 评估改为 Daily-CS 与 Monthly 分布；并输出 HAC t-stat（Newey–West）与 bootstrap CI。¹
- 预期方向：你会看到 pooled IC 与 Daily-CS IC 的差异，且“少数月份掩盖”的现象会被量化为：最差月、10%分位、连续负月。
- 资源成本：CPU 即可，几分钟。
- 成败标准：得到一份稳定可复用的“model_report.json”，作为后续 11 组的统一验收口径。

G2 对齐修正（解决双重滞后）

- 改动项：二选一（建议优先改 builder，改动集中且不影响已有特征实现）：
- 方案 B1：保留特征 shift(1)，但把序列窗口改为“包含 label 当日 t 的特征行”（因为该行只用到 t-1 信息，仍无泄漏）。

- 预期方向：短周期（5d）IC 应更明显提升；月度坏月深度减轻。
- 资源成本： $\approx 1 \times$ （10 个月重训）。
- 成败标准：`IC_5_10` 相对 G0 提升 $\geq +0.01$ ，且 `最差月(IC_5_10)` 不更差。若无提升，说明滞后不是主矛盾，可把该修改只作为“上线逻辑修正”保留，不作为提升路径。

G3 滚动窗口长度 12m

- 改动项：`train_window_months=12`（valid 仍 2m）。
- 预期方向：更快适应 regime，可能提升“近期 OOS 月份”，但方差变大、过拟合风险上升。
- 资源成本： $\approx 1 \times$ （10 个月重训），略快于 18m。
- 成败标准：月度胜率提升（ $\geq +10\text{pct}$ ）或最差月改善（ $\geq +0.02$ ），且均值不下降超过 0.005。

G4 滚动窗口长度 24m

- 改动项：`train_window_months=24`（valid 2m）。
- 预期方向：均值可能更稳、噪声更小，但适应漂移更慢，极端 regime 下可能更差。
- 资源成本： $\approx 1 \times$ （10 个月重训），略慢于 18m。
- 成败标准：`IC_5_10` 均值略降可以接受，但必须换来“尾部改善”：最差月 $\geq G0 + 0.02$ 或月度方差下降 $\geq 20\%$ 。

G5 验证方案改为月度 blocked CV（减少“最后两个月过拟合”）

- 改动项：在每次月度重训中，不再只用最后 2 个月做 valid，而是在训练窗内选 3 个离散月份做 validation fold（例如 -2m、-6m、-10m），早停指标用三折平均 IC。参考 rolling-origin 的思想（评估点随时间滚动）。

8

- 预期方向：平均 IC 不一定大幅提升，但“坏月”概率应下降，且更不容易被某个短窗口误导。
- 资源成本：每月训练需要多跑几次验证前向，总体约 $1.2 \times \sim 1.5 \times$ 。
- 成败标准：`连续负月最大长度` 下降，或 `10%分位月度 IC` 提升 $\geq +0.01$ 。

G6 三头保留，调低 3d 权重并加权 10d（focal-horizon 版本 A）

- 改动项：`loss_weights: (w3,w5,w10)=(0.2,1.0,1.2)`。
- 预期方向：保持多任务正则化，同时让 10d 不被 3d 噪声稀释；你的基线里 10d IC 明显高于 5d，这个配置通常会进一步放大优势。
- 资源成本： $\approx 1 \times$ 。
- 成败标准：`IC_10d` 提升 $\geq +0.01$ ，且 `RankIC_5_10` 不下降超过 0.01。

G7 三头保留，调低 3d 权重并加权 5d（focal-horizon 版本 B）

- 改动项：`loss_weights: (0.2,1.2,1.0)`。
- 预期方向：专门补你当前 5d IC 偏低的短板。
- 资源成本： $\approx 1 \times$ 。
- 成败标准：`IC_5d` 提升 $\geq +0.01$ ，且总体 `IC_5_10` 不下降。

G8 正则化与学习率调度（收敛更稳，减少月度方差）

- 改动项（建议组合成一组，否则你会在“调参泥潭”里浪费 2 周）：
- dropout 0.3 $\rightarrow$ 0.1（你模型很小且样本相对充足，0.3 可能过强）
- AdamW + cosine decay（含 warmup 5% steps）或 OneCycleLR（二选一）
- early stopping 仍以 valid 的 IC 为准
- 预期方向：均值提升小，但稳定性提升（坏月减少、方差降低）。
- 资源成本： $\approx 1 \times$ 。
- 成败标准：`月度 IC 标准差` 下降 $\geq 15\%$ ，且 `均值 IC_5_10` 不下降超过 0.005。

G9 市场状态特征扩展到“方向+结构”

- 改动项：在现有 3 个 market_state 上，新增 3 个（共 6 个），全部 shift(1)：

- market_breadth_1d: 横截面 ret1d>0 占比
- market_dispersion_1d: ret1d 横截面 std
- market_corr_20d: 过去 20d 成分股收益相关性的均值 (拥挤度 proxy)
- 预期方向: 减少 regime 翻向导致的“极端坏月”, RankIC 通常受益更明显。
- 资源成本: 需要重建 dataset (一次性成本) + 1×训练。
- 成败标准: 最差月(IC_5_10) 提升 $\geq +0.02$ 或 月度胜率 提升 $\geq +10\text{pct}$ 。

G10 损失从纯 L1 升级为 IC-aware (直接对齐 KPI)

- 改动项: 将 L1 损失替换/混合为 IC-aware: $\text{Loss} = \alpha \cdot L1 + (1-\alpha) \cdot (1-IC)$, α 建议 0.3 (偏重 IC)。你的仓库里已实现 IC-aware 版本 (在 Transformer 模块中), 可以迁移到 LSTM 训练脚本。⁹
- 预期方向: 均值 IC 上升、但 MAE 可能变差; RankIC 不一定同步上升。
- 资源成本: $\approx 1\times$ (但可能更敏感, 需要固定随机种子多跑 2 次做方差评估)。
- 成败标准: IC_5_10 提升 $\geq +0.01$ 且月度胜率不下降; 若仅均值提升但尾部更差, 则判为“研究候选, 不上线”。

G11 Rank-corr / 学习排序损失 (对齐 RankIC)

- 改动项: 在每个交易日横截面上, 加入 pairwise RankNet 损失 (或 listwise 近似), 与 L1 做加权: $\text{Loss} = L1 + \beta \cdot \text{RankLoss}$ (β 从 0.1 起试)。RankNet 是经典 pairwise 排序学习方法, 可用于直接优化排序质量。¹⁰
- 预期方向: RankIC 明显提升; IC 可能小幅提升或不变; 对“只看排序不看点估计”的选股更贴合。
- 资源成本: 需要实现“按 date 分组采样/成对构造”, 工程量略大; 训练耗时约 $1.2\times \sim 1.5\times$ 。
- 成败标准: RankIC_5_10 提升 $\geq +0.02$ 且 最差月(RankIC_5_10) 不更差; 否则不值得引入工程复杂度。

G12 校准触发条件重构 (只允许高置信翻向)

- 改动项: 保留 rolling18m 重训, 但把校准改为“极端保护机制”, 并用显著性做阈值:
- 仅当过去 K=3 个月 (或 60 交易日) Daily-CS IC 的 HAC t-stat < -2 且 $|\text{mean}| > 0.03$, 并且 5d 与 10d 同向时, 才 flip;
- 需要连续两次评估点都满足 (延迟确认)。⁶
- 预期方向: 不追求抬均值, 而是减少“误翻造成的灾难月”。
- 资源成本: 几乎 0 (复用预测结果即可模拟校准), 但要写好评估脚本。
- 成败标准: 最差月(IC_5_10) 明显改善 ($\geq +0.03$) 且均值不显著下降 (≤ -0.005)。如果改善不明显, 建议上线时完全关闭校准。

上线前风险与防泄漏检查清单

下面给出 12 条“最容易忽视但致命”的点, 并给出可自动化自检方法 (建议做成 pytest 或 CI job)。其中有些不一定是你目前已经犯的错, 但在你要改对齐/加特征/加归一化时最容易埋雷。

1) 特征与标签对齐是否出现“隐含多日滞后/错位”

自检: 随机抽样若干条样本, 追溯每个 `_t{}` 列实际对应的原始日期, 确认 label 日期 t 的最后一行特征最多使用到 t-1 (而不是 t-2、t-3)。

2) market_state 是否严格 shift(1), 并且 shift 发生在聚合之后

自检: 对 market_mom/vol/amount_z 的构造链路打 log, 验证每个日期的 market_state 仅使用更早日期的数据; 并检查“同日 ret1d 是否被直接用作当日市场特征”。

3) 任何 rolling/ewm 计算是否 accidentally 包含未来值

自检: 对所有 rolling/ewm 特征做单元测试: 把末尾未来几天数据置为 NaN, 特征历史部分不应变化。

4) train/valid/test 切分是否严格按日期唯一集合切分

自检：检查三个 split 的日期集合交集是否为空；不要只按样本行切（多股票面板会重复日期）。

5) rolling 重训时，训练集是否意外包含了当月 OOS 数据

自检：对每个 month_start，打印 train_range/valid_range，并断言 `max(train_date) < month_start` 且 `max(valid_date) < month_start`。

6) 任何标准化/截尾参数是否只在训练窗拟合（你一旦做 scaling，这是最高频的泄漏源）

自检：把 scaler 的拟合样本日期范围写入 artifact；CI 中断言不包含 valid/test 日期。

7) 股票池/行业成分是否存在生存者偏差（survivorship）

自检：确认 symbols 文件不是“按 2026 年现存股票”筛出来的；若是，至少在报告里明确这是 survivorship 的研究设定，并在线上前换成“每期可交易股票池”。

8) 停牌/缺价标签 NaN 的使用是否导致“未来窗口筛样”

自检：统计“被 NaN 掉的样本比例”在时间上的变化，并评估如果只用当日可交易条件过滤，样本分布是否显著改变；上线时严禁用未来信息过滤可交易池。

9) 复权/价格调整是否引入未来信息

自检：如果你未来改用“前复权/后复权”价格，请明确该复权口径是否为“历史快照不更新”或“动态复权”；Tushare 各接口的复权说明并不完全一致，需要固定口径并记录版本。¹¹

10) 评估时是否把 in-sample 预测混入了 OOS

自检：预测输出必须记录 `is_oos=True/False`、对应训练窗口与测试月份；聚合指标仅允许 `is_oos=True`。

11) 超参/特征选择是否对 test 做了隐式调参（数据窥探）

自检：把 test 锁死为“只在最后一次汇报使用”；日常实验只能看 train/valid 或滚动 OOS（walk-forward）里的“前半段”。

12) 成交额/成交量单位、缺失值填充是否在不同源/不同年份一致

自检：对每个特征列输出分布摘要（均值/分位数/缺失率）分年度对比；如果跨年分布突然跳变，优先排查数据源 schema 或单位变化。

最终建议

这里给你两条“可落地路线”：A 稳健优先、B 收益优先。两条都明确：预期收益、失败风险、计算成本、止损条件。

路线 A

主线

- 1) 先做 **G1（评估口径升级）+ G2（对齐修正）**：把“你到底在优化什么”这件事彻底钉死。
- 2) 在修正后的口径上，以 rolling18m、seq20、dim19 为核心架子，优先推进：
 - **G6/G7（3d 低权重 + 5/10d 重加权）**
 - **G9（market_state 扩展）**
 - **G8（调度 + 适度减 dropout）**
- 3) 校准默认关闭，只保留 **G12 的高置信熔断式 flip** 作为风控开关。

预期收益

- 均值层面：目标是把 `IC_5_10` 在你当前三头 rolling 的 0.067 附近再抬 +0.01~+0.02；

- 更重要的是：把“最差月”抬上来、把连续负月打断，让上线门禁能通过（这往往比抬均值更难，但也更关键）。

失败风险

- 如果 G2 对齐修正几乎不改善，说明瓶颈不是滞后，而是特征表达或目标函数；此时路线 A 仍可通过 G9/G8 提升稳定性，但均值上限可能有限。

计算成本

- 12 组中路线 A 实际需要跑的训练组大概 5~7 组，每组约 0.5~1.5 小时 GPU，总计 1~2 个工作日 GPU 时间即可跑完。

何时止损

- 如果在完成 G2 后，`IC_5_10` 仍无法稳定站上 0.06（Daily-CS 口径）且月度胜率 < 50%，则不要急于上线，转向路线 B 或先扩池/改目标函数。

路线 B

主线

围绕“你真正关心 RankIC + 横截面选股”这件事，直接把训练目标对齐排序能力：

- 1) 保留三头结构（3d 作辅助），但引入 **RankNet / listwise 排序损失**（G11），让模型在“同一日期的横截面”上学习排序，而不是只做点估计。¹⁰
- 2) 同时做 market_state 扩展（G9），并将 rolling 窗口长度从 18m 与 12m 中二选一（由你 monthly tail 决定）。
- 3) 校准不再做简单 flip，而是做“regime gating”：当 market_state 指示“反转 regime”时，启用另一套专家模型（或对预测做温和缩放/去方向化），而不是硬反号。

预期收益

- RankIC 端可能比路线 A 更容易拉开（+0.02~+0.05 的量级是有机会的），尤其在你当前“10d RankIC 很强、5d 偏弱”的结构下，排序损失能更直接补短板。

失败风险

- 工程复杂度明显提升（按日期分组采样、pairwise 构造、训练不稳定），且更容易过拟合到“某种排序结构”；如果你的信号本质很弱，RankLoss 可能把噪声当关系学。
- 更重要的是：上线门禁更难设（因为模型可能在 IC 上不增但在 RankIC 上增），需要你明确交易侧到底用什么（Top-K 选股还是回归值）。

计算成本

- 训练耗时约 1.5×，而且需要你至少做“多 seed”方差评估（否则很可能被偶然性误导）。

何时止损

- 如果 G11 在 2-3 次不同 seed 上都无法稳定提升 `RankIC_5_10`（提升 < +0.01 或最差月更差），立即止损回到路线 A（不要继续在 RankLoss 上堆工程）。

可直接执行的配置模板

下面给出 YAML 风格模板，你可以直接映射到你现有脚本参数（rolling 重训、horizon 权重、窗口长度、校准门禁）。其中我把“评估口径与上线门禁”也写进 config，避免后续口径漂移。

```

# =====
# Experiment Config Template
# =====

experiment:
  name: lstm_dim19_rolling_ic_boost
  seed: 42
  device: cuda
  output_dir: output/reports
  save_monthly_checkpoints: false

data:
  dataset_dir: data/datasets/lstm_sector70_19d_mkt_20210101_20260120
  date_range: [20210101, 20260120]
  universe: data/symbols_lstm_sectors_70.csv
  horizons: [3, 5, 10]
  seq_len: 20
  # alignment_mode:
  # - legacy: feature shift(1) + builder exclude t (可能双重滞后)
  # - include_t_feature_row: feature shift(1) + builder include t (推荐先试)
  alignment_mode: include_t_feature_row

rolling:
  enabled: true
  train_window_months: 18
  valid_window_months: 2
  # option: blocked_cv
  # use_monthly_blocked_cv: true
  # blocked_cv_month_offsets: [-2, -6, -10]
  use_monthly_blocked_cv: false

model:
  type: MTL_LSTM
  input_dim: 19
  hidden_size: 64
  num_layers: 2
  dropout: 0.3
  layer_norm: true

loss:
  type: l1 # options: [l1, ic_aware, l1_plus_ranknet]
  # horizon weights for [3d, 5d, 10d]
  loss_weights: [0.2, 1.0, 1.2]
  ic_aware:
    alpha: 0.3
  ranknet:
    beta: 0.1
  pair_sampling: all_pairs_in_day # or: topk_pairs
  group_by: date

```

```

training:
  optimizer: AdamW
  lr: 1.0e-4
  weight_decay: 1.0e-5
  batch_size: 32
  max_epochs: 40
  patience: 8
  grad_clip_norm: 1.0
  lr_scheduler:
    type: none    # options: [none, cosine_warmup, onecycle]
    warmup_ratio: 0.05

evaluation:
  primary_horizons: [5, 10]
  ic_mode: daily_cross_section # options: [pooled, daily_cross_section]
  report:
    metrics:
      - daily_ic_mean
      - daily_rankic_mean
      - icir
      - newey_west_tstat
      - monthly_win_rate
      - monthly_p10
      - monthly_min
      - max_consecutive_negative_months
      - quantile_spread_top_bottom # optional but recommended

gatekeeping:
  # Go-live thresholds (example)
  oos_months_min: 10
  require:
    daily_ic_mean_5_10: 0.05
    daily_rankic_mean_5_10: 0.08
    newey_west_tstat_ic_5_10: 2.0
    monthly_win_rate_ic_5_10: 0.60
    monthly_min_ic_5_10: -0.05
    max_consecutive_negative_months: 2

calibration:
  enabled: false
  # If enabled, use "high-confidence flip" only
  mode: high_confidence_flip
  lookback_months: 3
  flip_condition:
    min_abs_mean_ic: 0.03
    newey_west_tstat_threshold: -2.0
    require_horizon_consensus: true
    require_two_consecutive_checks: true

```

以上配置里，真正决定你“按月 vs 全时段”的关键字段是 `evaluation.ic_mode` 与 `gatekeeping`：它把“全 OOS 的显著性”和“按月的尾部/胜率”同时写成了硬标准，从流程上杜绝“被少数月份掩盖”。

1 6 A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix | NBER

https://www.nber.org/papers/t0055?utm_source=chatgpt.com

2 Critical values for multiple structural change tests | The Econometrics Journal | Oxford Academic

https://academic.oup.com/ectj/article-pdf/6/1/72/25961674/ectj0072.pdf?utm_source=chatgpt.com

3 Multitask Learning | Machine Learning

https://link.springer.com/article/10.1023/A%3A1007379606734?utm_source=chatgpt.com

4 7 THE FUTURE OF

https://rpc.cfainstitute.org/sites/default/files/-/media/documents/book/rf-publication/2018/future-of-investment-management-kahn.pdf?utm_source=chatgpt.com

5 Spearman rank correlation coefficient | statistics | Britannica

https://www.britannica.com/science/Spearman-rank-correlation-coefficient?utm_source=chatgpt.com

8 Cross-validation for time series – Rob J Hyndman

https://robjhyndman.com/hyndsight/tscv/?utm_source=chatgpt.com

9 Information Coefficient (IC) Definition | Nasdaq

https://www.nasdaq.com/glossary/b/information-coefficient?utm_source=chatgpt.com

10 Learning to Rank using Gradient Descent

https://www.microsoft.com/en-us/research/wp-content/uploads/2005/08/icml_ranking.pdf?utm_source=chatgpt.com

11 Tushare数据

https://www.tushare.pro/document/2?doc_id=296&utm_source=chatgpt.com